Malware Detection

차례

- 목표
- 기존 연구의 문제점
- Dataset
- Library
- 시스템 구성도
- 성능

목표

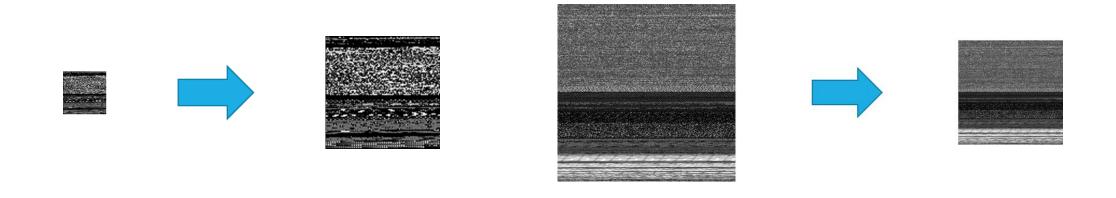
• Malware 파일을 이미지화 시켜 malware 역할을 하는 부분을 detection 한다.

 Malware 파일을 이미지화 시켜서 convolution layer 거쳤을 때 activation되는 영역을 RCNN으로 학습시켜 malware 역할을 하는 부분을 detection 한다.

○ 기존의 CNN을 이용해 malware를 판단하면 큰 크기의 malware의 특징 점들이 뭉게지기 때문에 큰 크기의 파일은 판단하기 어려울 수 있는 문제점이 있다.

기존 연구의 문제점

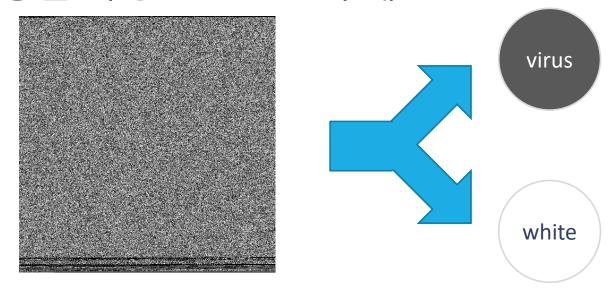
• CNN에 입력되는 이미지의 resize 예



• 기존의 CNN을 이용해 malware를 판단하면 큰 크기의 malware의 특징 점들이 뭉게 지기 때문에 큰 크기의 파일은 판단하기 어려울 수 있는 문제점이 있다.

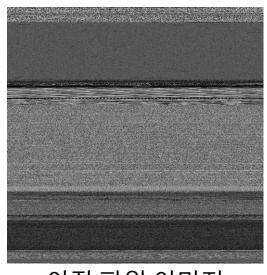
기존 연구의 문제점

• CNN을 이용한 악성코드 판단의 예

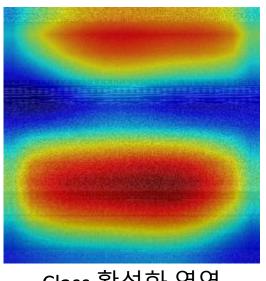


• CNN을 학습시켰을 때 activation 되는 영역을 이용하여 RCNN을 학습시켜 서 큰 크기 파일에서 여러Malware 영역을 detect한다.

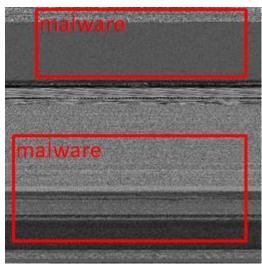
- 악성코드와 일반 파일을 이미지화한 파일을 CAM(Class Activation Mapping)을 이용해 활성화 영역을 학습하여 파일의 크기를 조정하지 않고 과 R-CNN을 통해 판단한다.
- 또한 CAM과 R-CNN을 이용하면 악성코드 동작 영역을 파악할 수 있다.



이진 파일 이미지

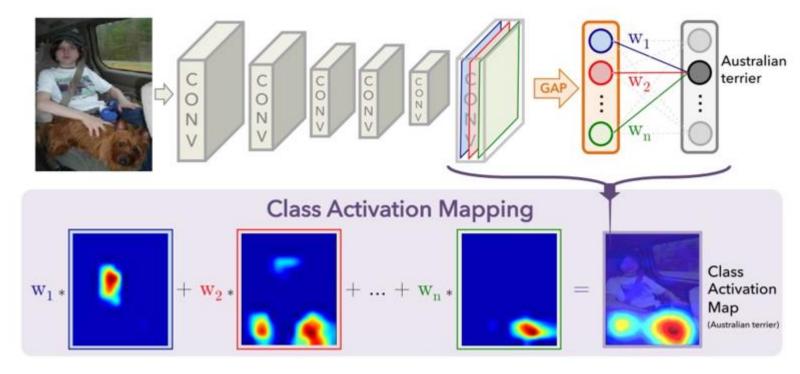


Class 활성화 영역



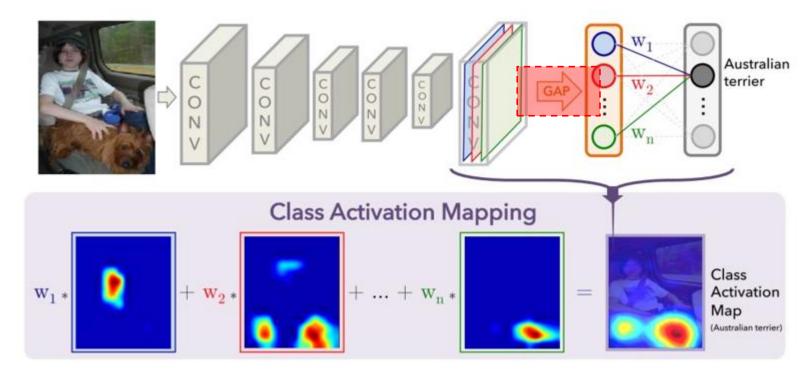
R-CNN 결과

CAM(Class Activation Mapping)



B. Zhou, A. Khosla et al., "Learning Deep Features for Discriminative Localization," CVPR 2016.

CAM(Class Activation Mapping)

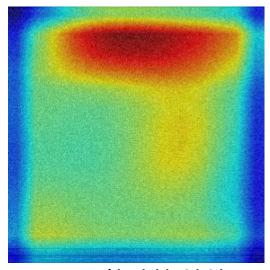


B. Zhou, A. Khosla et al., "Learning Deep Features for Discriminative Localization," CVPR 2016.

- CAM(Class Activation Mapping)
 - CAM은 이미지가 FC layer를 지나면서 특정 class에 대해 활성화 되는 영역을 보여준다.

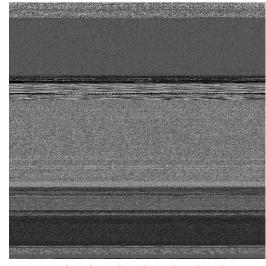


이진 파일 이미지

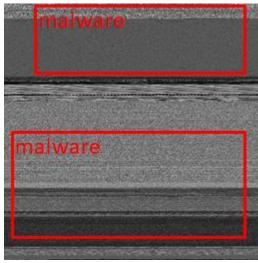


Class 활성화 영역

- R-CNN
 - 이미지 전체에서 class에 해당하는 객체를 찾고 객체 영역을 출력한다.



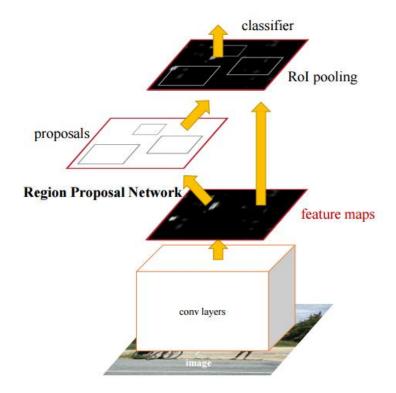
이진 파일 이미지



R-CNN 결과

Library

Faster R-CNN



Ren, Shaoqing, et al., "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks," CVPR 2015.

• Virus - 20,462개

• **White** – 19,766개

총 40,228개의 데이터로 구성

• Virus - 20,462개

∘ White - 19,7667∦

총 40,228개의 데이터로 구성

→ train: 26,820 / validation: 6704 / test: 6704
4:1:1(6 fold)

Virus

◦ VirusShare 사이트에서 제공

Virus Share.com - Because Sharing is Caring

Home - About - Hashes - Research - Support the Project

Please login to search and download.

System currently contains 29,548,065 samples.

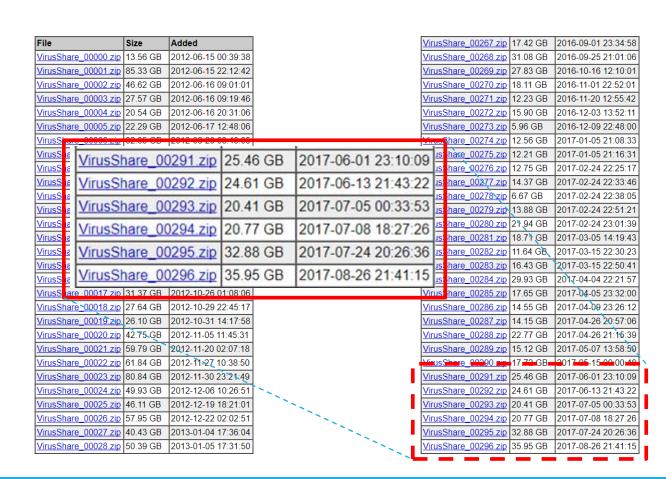
Please note that this site is constantly under construction and might be broken.

Latest sample added to the system:

	MD5	56f827366e45d22686ec09e27e7f1f3a		
	SHA1	56ca4c57bd523f35159e565ba0c312fe240d698f		
	SHA256	8008b2964560e2b7cc971ce08156e32a68fd6f5ba9905664cbfa02be015deb89		
SSDeep	786432:wW4	knqVqQHvc2tbIBfWuz5hFrbIrqVBc+ClBcxD9icWx/y7fE996I2DxgioKtZUm:wWznbQ02tweO5hFrbIu7k9/wI2DjMXuD		
Size	49,710,703 b	,710,703 bytes		
File Type	Java archive	ava archive data (JAR)		
Detections	Dr⊮eb = Adware.Leadbolt.12.origin NANO-Antivirus = Riskware.Android.Leadbolt.dkzuxh			
ExIF Data	File Type MIME Type Zip Required V Zip Bit Flag Zip Compressio Zip Modify Dat Zip CRC Zip CRC Zip Compressed Zip Uncompress Zip File Name	nge Date/Time : 2017:11:12 08:31:08-05:00 : ZIP : application/zip ersion : 20 : 0x0808 n : Deflated e : 2015:04:15 14:41:19 : 0x32517367 Size : 400 ed Size : 4760 : assets/bin/Data/0000000000000000000000000000000000		
VirusTotal Rep	oort submitted	2015-04-25 18:47:53 UTC		
VirusShare int	fo last updated	± 2017-11-12 13:39:21 UTC		

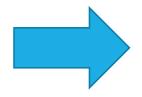
Virus

• 최신 파일에 대해서 torrent 피어 제공 → 최신 순으로 데이터 다운로드



Virus

VirusShare_00293.zip (다운로드) VirusShare_00294.zip (다운로드) VirusShare_00295.zip (다운로드) VirusShare_00296.zip (다운로드)



각각 65,536 개의 malware 제공

Virus

데이터 개수: 196,608

VirusShare_00293.zip VirusShare_00294.zip

VirusShare 00295.zip

VirusShare_00296.zip

application/CDFV2-unknown

application/gzip

application/java-archive application/msword

application/octet-stream

application/pdf

application/vnd.ms-cab-compressed

application/vnd.ms-excel application/vnd.ms-office

application/vnd.ms-powerpoint

application/vnd.openxmlformats-officedocument... text/html

application/x-7z-compressed

application/x-dosexec

application/x-elc

application/x-executable

application/xml

application/x-msi

application/x-rar

application/x-setupscript application/x-sharedlib

application/x-shockwave-flash

application/zip application/zlib

image/gif

image/jpeg

image/png

image/x-icon

message/rfc822

text/plain

text/rtf

text/rtf,application/zlib

text/troff text/x-asm

text/x-pascal

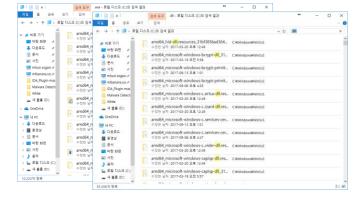
text/x-php

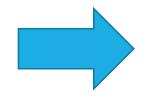
196,608개 → 응용프로그램 및 스크립트 유형

20,462개만 사용

White

Windows

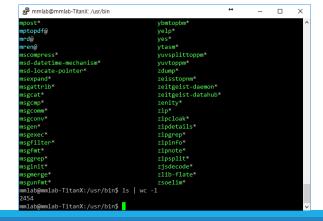


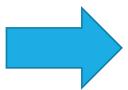


*.exe, *.dll 파일만 추출

→ **17,963**개

Linux





Link를 제외한 실행 파일만 사용

→ 약 1,803개

19,766개

• HW

- CPU: Intel® Core™ i7-7700 CPU @ 4.20GHz
- Main Memory: 32GB
- GPU: GeForce GTX 1080 Ti (11GB GDDR5)

OS

Ubuntu 16.04.5 LTS

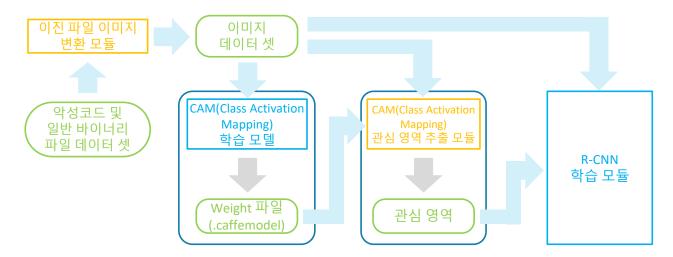
System SW

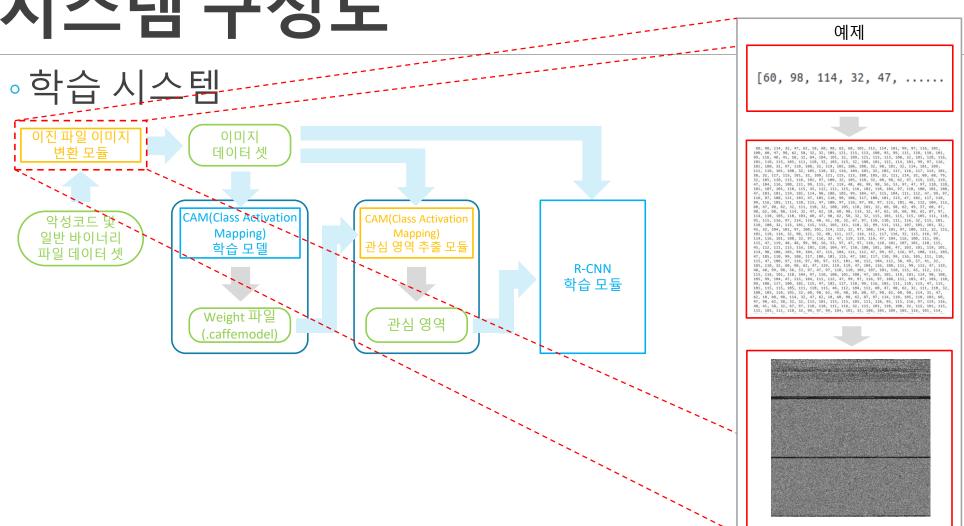
• Python: 2.7.13

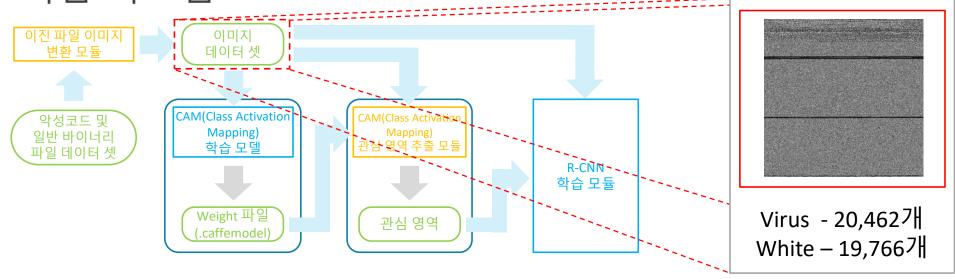
Caffe: 1.0.0

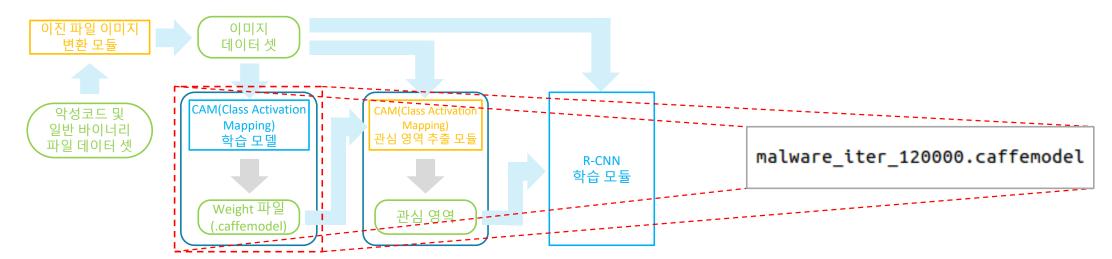
Pycaffe: 1.0.0

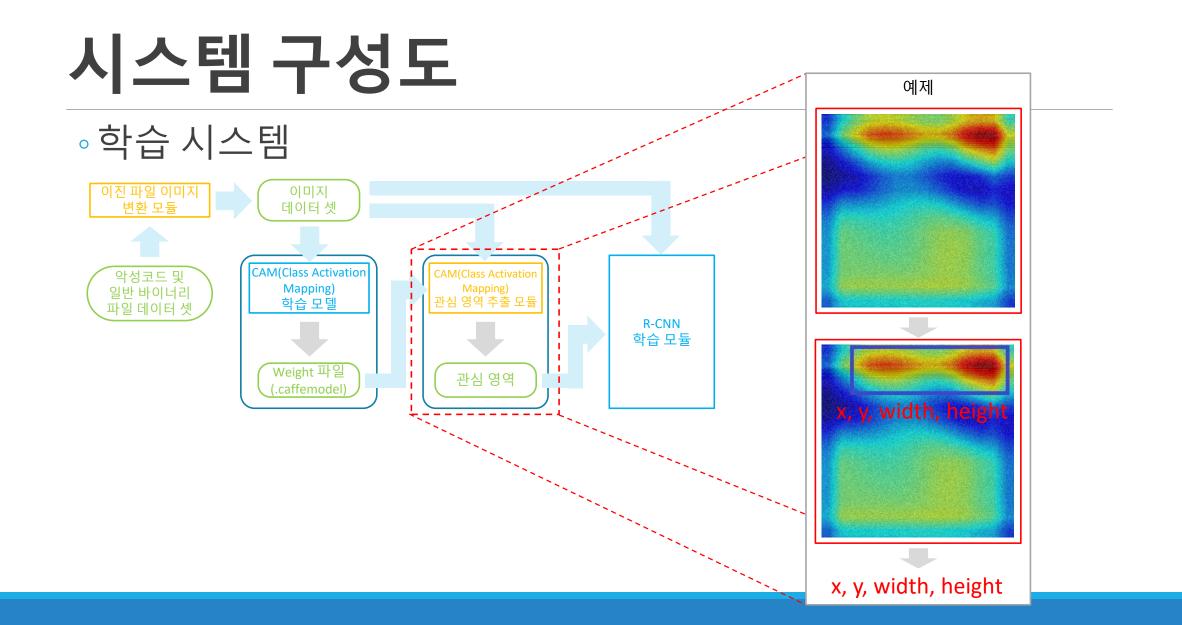
OpenCV: 2.4.9

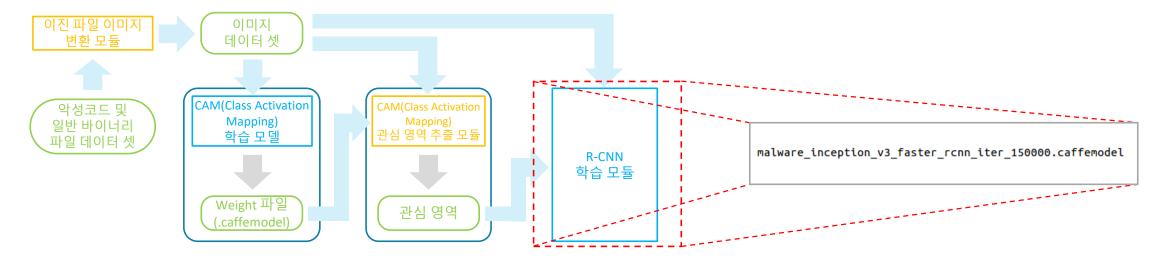


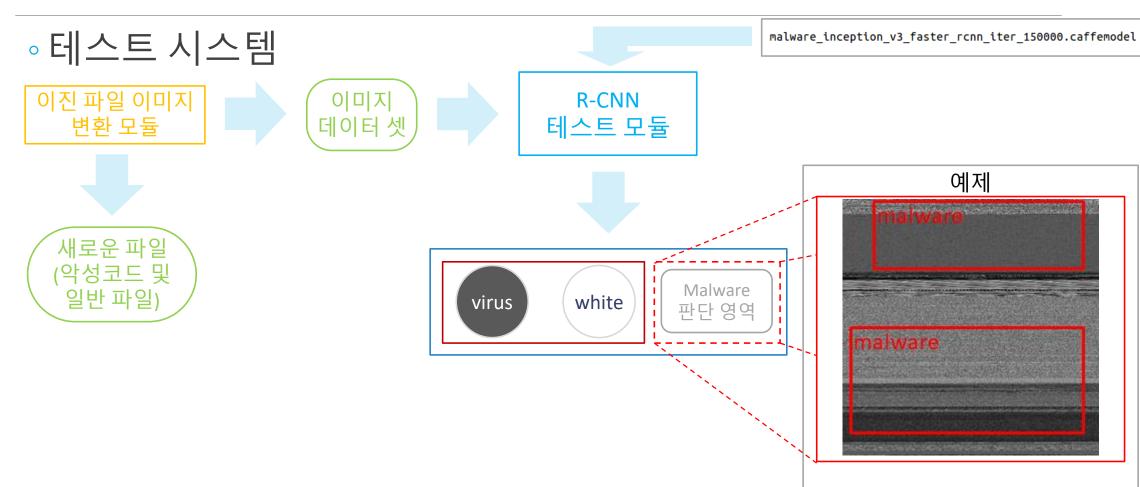












Class Activation Mapping

	VGG 16	VGG 19	Inception v3	Inception v4
Recall	98.21	99.32	99.24	99.38
Precision	50.44	49.13	98.73	96.19

학습 옵션

test_iter: 1000

test_interval: 3000

base_lr: 0.001

lr_policy: "step"

gamma: 0.1

stepsize: 40000

max_iter: 160000

momentum: 0.9

weight_decay: 0.0005

snapshot: 10000

Class Activation Mapping

	VGG 16	VGG 19	Inception v3	Inception v4
Recall	98.21	99.32	99.24	99.38
Precision	50.44	49.13	98.73	96.19

학습 옵션

test_iter: 1000

test_interval: 3000

base_lr: 0.001

lr_policy: "step"

gamma: 0.1

stepsize: 40000

max_iter: 160000

momentum: 0.9

weight_decay: 0.0005

snapshot: 10000

• R-CNN

	VGG16	Inception
Recall	99.62	99.27
Precision	48.17	51.7

학습 옵션

base_lr: 0.001

lr_policy: "step"

gamma: 0.1

stepsize: 150000

display: 100

average_loss: 100

iter_size: 1

momentum: 0.9

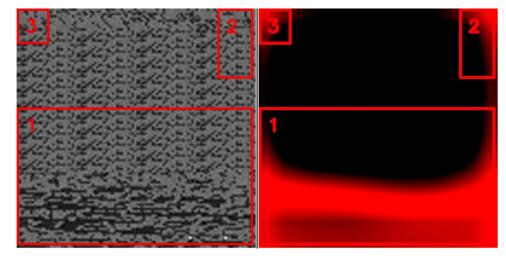
weight_decay: 0.0005

snapshot: 10000

iter_size: 2

성능:문제점진단

Class Activation mapping



- Bonding box 생성 시 작은 부분도 상자를 생성하여 noise가 다량 포함되어있음
 - → Filtering 필요

• R-CNN

	VGG16	Inception
Recall	99.34	98.97
Precision	49.12	51.04

학습 옵션

base_lr: 0.001

lr_policy: "step"

gamma: 0.1

stepsize: 150000

display: 100

average_loss: 100

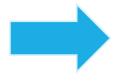
iter_size: 1

momentum: 0.9

weight_decay: 0.0005

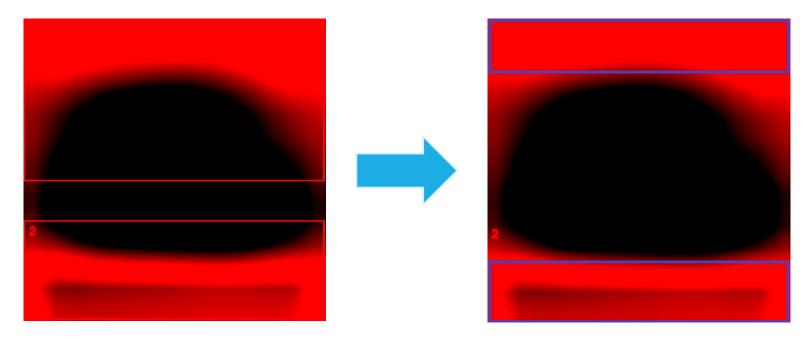
snapshot: 10000

iter_size: 2



성능이 개선되지 않음

향후 개선 방향



◦ Bounding box에 포함되는 가장자리의 noise를 제거하여 R-CNN을 다시 학습

→ 수작업 진행 예정